llm-setup

🛠️ تشغيل الـ LLM (Ollama) — خطوة بخطوة من السيرفر لحد الـ VM

> اقرأ `llm-basics.md` الأول لو أي مصطلح مش واضح.
> **الترتيب مهم**: نفّذوا المراحل بالترتيب. بعد كل خطوة في **"المفروض تشوف"**، ولو مشفتهاش وقّف وابعت لقطة شاشة أو نص الخطأ.

الصورة الكبيرة

```
[لاب قوي (Windows)]  ← Ollama + الموديل
          ▲
          |  Tailscale (شبكة خاصة)
          |
[VM بتاعة كل عضو (Xubuntu)] ← الكود بيبعت الجملة ويستلم اسم الأمر
```

المرحلة	مين بينفّذها	الهدف
0	الفريق كله	قرارات قبل البداية
1	صاحب اللاب القوي	تشغيل Ollama والموديل على ويندوز
2	صاحب اللاب القوي	الجدار الناري + Tailscale
3	كل عضو (غير صاحب اللاب)	يوصّل الـ VM بتاعته بالسيرفر
4	صاحب اللاب القوي	يوصّل الـ VM بتاعته هو كمان
5	الكل	اختبار نهائي وضبط الكود

المرحلة 0: قرارات قبل ما نبدأ (الفريق كله)

- [ ] **مين صاحب اللاب القوي؟** كارت NVIDIA بذاكرة أكبر، ثم رام أكبر · متوصل بالكهربا · إنترنت مستقر · صاحبه ملتزم ومش بيقفله وقت الشغل.
- [ ] **اسم الموديل المبدئي** (مثال: `qwen3.5:2b`). الموديل النهائي بيتحدد بعدين بالاختبار على أضعف جهاز، فمتتعلقوش بيه دلوقتي.
- [ ] **كل عضو عنده حساب** Google (Gmail) أو Microsoft أو GitHub عشان يسجّل في Tailscale.
- [ ] **كل عضو عمل Import** للـ VM الموحدة (Xubuntu) وبتفتح ومعاها إنترنت.

المرحلة 1: صاحب اللاب القوي — Ollama على ويندوز

1) ثبّت Ollama (لو مش مثبّت): حمّله من https://ollama.com/download وشغّل ملف `OllamaSetup.exe`.
✅ المفروض تشوف أيقونة Ollama جنب الساعة (الـ tray).

2) **اتأكد إنه شغال:** افتح PowerShell واكتب:

```
ollama -v
```

✅ المفروض يظهر رقم الإصدار.

3) **نزّل الموديل:**

```
ollama pull qwen3.5:2b
```

✅ المفروض ينزل لحد ما يخلص من غير خطأ (محتاج إنترنت ومساحة على الهارد).

4) **اتأكد إن الموديل موجود:** افتح المتصفح على:

```
http://localhost:11434/api/tags
```

✅ المفروض تشوف نص JSON فيه اسم الموديل.

5) **خلّي Ollama يسمع للشبكة، مش للجهاز بس:**

1. اقفل Ollama تمامًا من أيقونة الـ tray (Quit).
2. ابحث في ويندوز عن `environment variables` وافتح "Edit environment variables for your account".
3. اضغط **New** واكتب: الاسم `OLLAMA_HOST` · القيمة `0.0.0.0:11434` ← OK.
4. شغّل Ollama تاني من قائمة Start.

✅ المفروض يشتغل عادي. لو ظهرت نافذة Windows Defender Firewall، اضغط Allow، وهنراجعها في المرحلة 2.

6) **خلّي اللاب ميناموش وقت الشغل:** Power & sleep ← System ← Settings ← خلّي Sleep على "Never" وهو موصول بالكهربا. *(توصية مني)*

المرحلة 2: صاحب اللاب القوي — Tailscale والجدار الناري

1) **اعمل حساب Tailscale** من https://tailscale.com بحسابك الشخصي، ونزّل البرنامج على ويندوز وسجّل دخول.
✅ المفروض يظهر جهازك في لوحة الإدارة (Admin console) في صفحة Machines بعنوان يبدأ بـ `100.`.

2) اعرف عنوان السيرفر على Tailscale: من اللوحة، أو من PowerShell:

```
tailscale ip -4
```

✅ المفروض يرجع عنوان شكله `100.x.x.x`. اكتبه، هتديه للفريق.

3) قيّد الجدار الناري بحيث البورت 11434 يتفتح لشبكة Tailscale بس:

1. افتح Windows Defender Firewall with Advanced Security.
2. Inbound Rules ← New Rule ← Port ← TCP، وفي Specific local ports اكتب `11434` ← Allow the connection.
3. سمّيها `Ollama-Tailscale`.
4. بعد ما تتعمل: دوس عليها دبل كليك ← تبويب Scope ← في Remote IP address اختار These IP addresses ← Add ← اكتب `100.0.0.0/8`.

(الشاشات دي قياسية في ويندوز، بس راجع أسماء الخيارات عندك لأنها ممكن تختلف شوية بين الإصدارات.)

4) راجع القواعد التانية: لو في قواعد قديمة اسمها `ollama` اتعملت لما ضغطت Allow في المرحلة 1، عطّلها أو احذفها، لأنها ممكن تسيب البورت مفتوح لأي حد على الشبكة. *(Ollama مفيهوش تسجيل دخول، فمتفتحوهوش للإنترنت.)*

5) اختبر من نفس اللاب: افتح المتصفح على:

```
http://100.x.x.x:11434
```

(بدل `100.x.x.x` بعنوانك من الخطوة 2).
✅ المفروض تشوف `Ollama is running`.

المرحلة 3: كل عضو — يوصّل الـ VM بالسيرفر

> ينفّذها كل عضو جوه الـ Xubuntu VM بتاعته، بعد ما يعمل Import للـ VM.

1) اعمل حساب Tailscale مجاني خاص بيك من https://tailscale.com.

> ⚠️ ليه حساب لكل واحد؟ الخطة المجانية فيها 3 مستخدمين بس، وفريقكم 7. فمينفعش الكل يدخلوا نفس الشبكة. الحل: كل واحد حسابه، وصاحب اللاب يشارك السيرفر معاه (Node Sharing)، والمشاركة مش بتتحسب ضمن حد الـ 3.

2) ثبّت Tailscale جوه الـ VM من صفحة التثبيت الرسمية لـ Linux على https://tailscale.com، وسجّل دخول بحسابك:

```
sudo tailscale up
```

✅ المفروض يطلعلك رابط تفتحه في المتصفح وتسجّل دخول بيه.

3) ابعت لصاحب اللاب إيميل حسابك (اللي سجّلت بيه في Tailscale).

4) صاحب اللاب بيشارك السيرفر معاك: من Admin console ← صفحة Machines ← قايمة الجهاز (النقط التلاتة) ← Share ← يبعتلك رابط الدعوة.

5) افتح الرابط وإنت مسجّل دخول بحسابك ووافق على المشاركة.
✅ المفروض السيرفر يظهر في قايمة أجهزتك.

(خطوات الـ Share بتاخد شكلها من توثيق Node Sharing عند Tailscale، فتأكدوا من الصفحة الرسمية لو اختلفت.)

6) اتأكد من الاتصال من الـ VM:

```
tailscale status
curl http://100.x.x.x:11434
```

(بدل `100.x.x.x` بعنوان السيرفر اللي صاحب اللاب اداهولك).
✅ المفروض ترجع `Ollama is running` .

لو فشل: اتأكد إن (1) `tailscale status` بيقول إنك متصل، (2) المشاركة اتقبلت، (3) Ollama اتعمله Quit وتشغيل بعد ضبط (4) `OLLAMA_HOST` ، اللاب السيرفر مش نايم، (5) قاعدة الجدار الناري لسه موجودة.

المرحلة 4: صاحب اللاب القوي — الـ VM بتاعته

الـ VM بتاعك على نفس اللاب، فهتستخدم **نفس طريقة باقي الفريق**، وده أبسط وأضمن مع قاعدة الجدار الناري اللي قصرناها على Tailscale:

1. ثبّت Tailscale جوه الـ VM وسجّل دخول **بنفس حسابك اللي على اللاب** (نفس الشبكة، مش محتاج مشاركة).
2. اختبر:

```
curl http://100.x.x.x:11434
```

✅ المفروض ترجع `Ollama is running` .

(بديل: تسمح في الجدار الناري بنطاق شبكة الـ VM كمان، بس محتاج تعرف نطاقه وده بيختلف بين NAT وBridged، فالأول أبسط.)

المرحلة 5: اختبار نهائي وضبط الكود (كل عضو)

1) اختبر إن الموديل بيرد فعلًا:

```
curl http://100.x.x.x:11434/api/generate -d '{
  "model": "qwen3.5:2b",
  "prompt": "اكتب كلمة واحدة بس: تم",
  "stream": false
}'
```

✅ المفروض يرجع JSON فيه حقل `response` . أول طلب ممكن ياخد وقت أطول لأن الموديل بيتحمّل في الذاكرة. *(اسم الموديل لازم يطابق اللي اتنزّل.)*

2) خلّي عنوان السيرفر إعداد دايم في الـ VM:

```
echo 'export OLLAMA_URL=http://100.x.x.x:11434' >> ~/.bashrc
source ~/.bashrc
echo $OLLAMA_URL
```

✅ المفروض يطبع العنوان.

3) في الكود (دور 3) العنوان يتقري من الإعداد، مش مكتوب جوه الملف:

```
import os
OLLAMA_URL = os.getenv("OLLAMA_URL", "http://localhost:11434")
```

بكده كل عضو بيشغّل نفس الكود، وبس بيغيّر `OLLAMA_URL` لو السيرفر اتغيّر.

بديل سريع: Ollama جوه الـ VM (من غير سيرفر)

لو مفيش سيرفر أو الشبكة مش شغالة، شغّلوه محليًا جوه الـ VM:

```
curl -fsSL https://ollama.com/install.sh | sh   # التثبيت (محتاج إنترنت)
ollama -v                                       # المفروض يظهر رقم الإصدار
ollama pull qwen3.5:2b                          # نزّل الموديل
curl http://localhost:11434/api/tags            # المفروض يظهر الموديل
export OLLAMA_URL=http://localhost:11434
```

لازم الموديل يكفي في رام الـ VM (مش رام الجهاز كله).

قرارات مفتوحة

- ☐ الموديل النهائي (بالاختبار على أضعف جهاز، دور 6).

- [ ] هل العرض النهائي هيعتمد على السيرفر؟ لو أيوه، يتكتب في التقرير كمتطلب، والكود يرجع للـ Fallback لو السيرفر مردّش.

لازم الفريق يجرّبه ويقيسه (متتحطش أرقام من عندنا)

- زمن الرد من الـ VM للسيرفر.
- تأثير 7 أشخاص بيستخدموا السيرفر في نفس الوقت.
- إن Tailscale والـ Node Sharing بيشتغلوا فعلًا على الـ VM عندكم.

المصادر

- تثبيت Ollama على لينكس: https://docs.ollama.com/linux
- الـ FAQ الرسمي (`OLLAMA_HOST` على ويندوز): https://docs.ollama.com/faq.md
- الـ API الرسمي (`/api/generate`): https://docs.ollama.com/api/generate.md
- خطوات ويندوز والجدار الناري و`Ollama is running`: https://www.blackmoreops.com/how-to-access-ollama-from-another-pc-on-your-local-network/
- خطر فتح Ollama من غير مصادقة: https://www.digitalcitizen.life/how-to-expose-ollama-to-the-network-on-windows/
- مثال فريق بيشارك Ollama عبر Tailscale وقاعدة الجدار الناري `100.0.0.0/8`: https://git.azcomputerguru.com/azcomputerguru/claudetools/commit/59955110113268131f626def6c8ceb8f730d4674
- حدود خطة Tailscale الشخصية (3 مستخدمين): https://tailscale.com/pricing/faq
- مشاركة الأجهزة بدل إضافة مستخدمين (نقاش مجتمع): https://forum.syncthing.net/t/tcp-port-tunneling-through-syncthing-network/23945?page=2